Arquitectura de autoservicio con catálogo de modelos

Análisis de video con IA — cada área agrega sus cámaras, elige modelos y define sus avisos

Autor: Dev · Octubre 2026 · Complemento del documento “Análisis de video con IA en local”

Objetivo: que cualquier área de la planta pueda, junto con IT, agregar una cámara al sistema, elegir qué modelos ya entrenados quiere usar (personas, conteo, humo, EPP, etc.), configurar el canal donde recibe notificaciones y decidir en qué eventos se ejecuta el VLM, sin desarrollo nuevo y sin reiniciar el sistema.

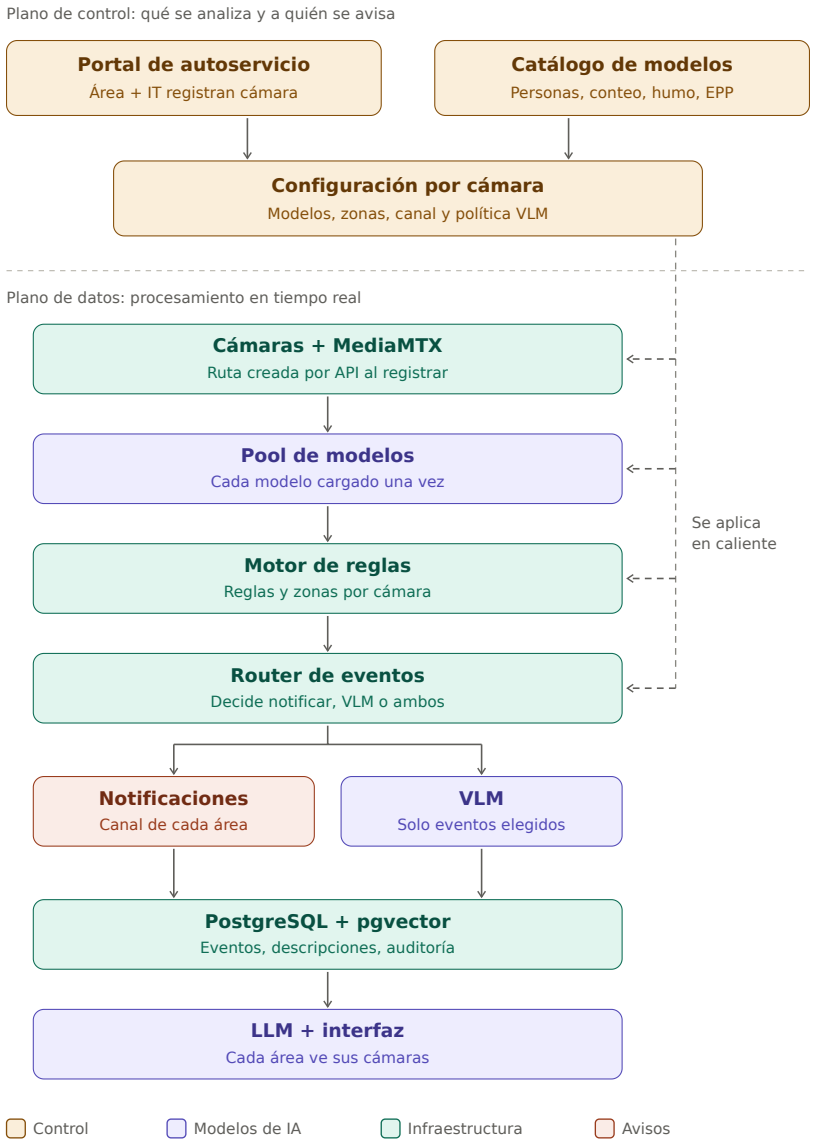


Figura 1. Plano de control (configuración) y plano de datos (procesamiento en tiempo real).

1. Idea central: dos planos

El cambio clave es separar el sistema en dos planos:

- **Plano de control:** donde las personas configuran qué quieren analizar y a quién se avisa (portal, catálogo y configuración por cámara).
- **Plano de datos:** el que procesa video en tiempo real y obedece esa configuración. Los cambios se aplican en caliente, sin reiniciar nada.

2. Flujo de alta de una cámara

1. **IT registra la cámara** en el portal (URL RTSP, credenciales, red). El sistema prueba la conexión y crea la ruta en MediaMTX por su API, sin reiniciar.
2. **El área elige del catálogo** los modelos que quiere: personas, conteo, humo, EPP; uno o varios.
3. **Dibuja sus zonas y ajusta las reglas** que ofrece cada modelo (por ejemplo, umbral de conteo o tiempo en zona).
4. **Elige su canal de notificación** (Teams, Telegram, correo) y para qué eventos.
5. **Marca qué eventos pasan por el VLM.** Por ejemplo: “humo” solo notifica de inmediato, mientras que “persona sin casco” notifica y además genera descripción.

3. Componentes

Componente	Función
Portal de autoservicio	Interfaz donde IT da de alta la cámara y el área configura modelos, zonas, reglas, canal y política VLM. IT aprueba cada alta.
Catálogo de modelos	Registro de modelos ya entrenados y reutilizables, cada uno con su ficha (ver sección 4).
Configuración por cámara	Guarda qué modelos usa cada cámara, sus zonas, reglas, canal de aviso y qué eventos van al VLM. Es la “fuente de verdad” que lee el plano de datos.
Cámaras + MediaMTX	Recibe los streams. Al registrar una cámara, se crea su ruta por API sin reiniciar el servidor.
Pool de modelos	Cada modelo se carga una sola vez en memoria y atiende a todas las cámaras suscritas.
Motor de reglas	Convierte detecciones en eventos según las reglas y zonas configuradas para cada cámara.
Router de eventos	Según la configuración de la cámara, envía cada evento a notificar, al VLM o a ambos.

Notificaciones	Entrega las alertas al canal que eligió cada área, con miniatura y enlace al clip.
VLM	Describe solo los eventos que el área marcó, usando el prompt asociado a ese tipo de evento.
PostgreSQL + pgvector	Guarda eventos, detecciones, descripciones, embeddings y la auditoría de cambios de configuración.
LLM + interfaz	Consultas y reportes; cada área ve solo sus cámaras y eventos.

4. El catálogo: lo que permite reutilizar

Cada modelo entrenado se registra una sola vez con su ficha. Cuando el área de almacén quiere conteo de personas, no se entrena nada: se suscribe al modelo que ya existe.

Campo de la ficha	Ejemplo (modelo “Humo”)
Qué detecta	Humo y flama visibles
Eventos que puede emitir	`humo_detectado`, `flama_detectada`
Reglas que acepta	Confianza mínima, duración mínima, zona
Prompt de VLM por defecto	Uno por tipo de evento; el área puede ajustarlo
Versión y licencia	v1.2, Apache 2.0
Costo de GPU	Estimado por cámara y por fps de análisis

> Los prompts por dominio viven en el catálogo junto al tipo de evento. Así, el VLM usa automáticamente el prompt correcto según el evento que recibe.

5. Por qué escala

Pool de modelos compartido

Si 10 cámaras usan detección de personas, hay un solo modelo procesando frames de las 10, no 10 copias. El costo de GPU crece con los frames analizados, no con el número de suscripciones.

Router de eventos

Decide el destino de cada evento según la configuración de esa cámara: solo notificar, solo VLM o ambos. Las alertas críticas (humo, salida bloqueada) salen de inmediato, sin esperar al VLM, que es la pieza más costosa.

6. Ejemplo de configuración

Área / cámara	Modelos	Evento	Notificar	VLM
Almacén / cam-07	Personas, conteo	Aforo > 20 personas	Telegram almacén	No
Producción / cam-12	EPP	Persona sin casco	Teams seguridad	Sí
Pintura / cam-03	Humo	Humo detectado	Teams + correo	No
Embarques / cam-15	Personas	Persona en andén fuera de horario	Telegram vigilancia	Sí

7. Controles recomendados

- **Aprobación de IT** en cada alta de cámara (credenciales, red y segmentación).
- **Costo estimado visible** en el portal antes de activar modelos o el VLM, para evitar saturar la GPU.
- **Permisos por área:** cada área solo ve y configura sus propias cámaras.
- **Auditoría:** registro de quién cambió qué configuración y cuándo.
- **Gobierno del catálogo:** un modelo nuevo entra al catálogo solo con métricas de validación, versión y licencia revisada.